

ESTUDO DE CASO - BELLABEAT

Por Matheus Souza de Macedo Santos

Sumário

I. Introdução

- a. Cenário

II. Fase do Questionamento

III. Fase da Preparação

- a. Os dados
- b. Confiabilidade dos dados
- c. Organizando os dados no Microsoft Excel
- d. Preparando o RStudio

IV. Fase do Processamento

- a. Log de comandos e processos de limpeza
- b. Explicação de cada etapa

V. Fase da Análise

- a. Respondendo perguntas
- b. Resumo das descobertas

VI. Fase do Compartilhamento

- a. Carregamento de dados no Power BI
- b. O público da Fitbit
- c. As funções mais utilizadas da Fitbit
- d. Relação entre público e função

VII. Fase da Ação (Conclusão)

Introdução

Bem-vindo ao estudo de caso de análise de dados da Bellabeat! Neste estudo de caso, serão realizadas diversas tarefas típicas de um analista de dados júnior. O objetivo é analisar dados de dispositivos inteligentes para obter informações sobre como os consumidores estão utilizando esses dispositivos, a fim de orientar a estratégia de marketing da empresa.

Além de aprimorar minhas habilidades e praticar o uso das ferramentas comuns na análise de dados, este estudo também visa demonstrar minha proficiência no manuseio dessas ferramentas. Durante o documento, o leitor notará a alternância entre as seguintes ferramentas: SQL, R, Excel e Power BI.

O processo foi dividido nas etapas: Perguntar, Preparar, Processar, Analisar, Compartilhar e Agir, etapas estas que são classificadas pela equipe do Google como o ciclo ideal para uma análise de dados eficaz.

Este estudo de caso foi recomendado pelo Google Career Certificates como o projeto final para o Certificado Profissional de Análise de Dados, a fim de aplicar todo o conhecimento adquirido durante o curso.

Cenário

Você é um analista de dados júnior que trabalha na equipe de analistas de marketing da Bellabeat, uma fabricante de produtos de alta tecnologia voltados à saúde para mulheres. A Bellabeat é uma pequena empresa de sucesso, mas tem potencial para adquirir maior participação no mercado global de dispositivos inteligentes. Urška Sršen, co-fundadora e CEO da Bellabeat, acredita que a análise de dados de condicionamento físico a partir de dispositivos inteligentes pode ajudar a abrir novas oportunidades de crescimento para a empresa. Foi solicitado que você se concentre em um dos produtos da Bellabeat e analise dados de dispositivos inteligentes para obter informações sobre como os consumidores estão usando esses dispositivos. Os insights que você descobrir ajudarão a orientar a estratégia de marketing da

empresa. Você apresentará sua análise à equipe executiva da Bellabeat juntamente com suas recomendações de alto nível para a estratégia de marketing da empresa.

Fase do questionamento

Antes de iniciarmos o processo de análise dos dados, é importante determinarmos o objetivo desta análise. Realizar perguntas diretas e relevantes para o caso pode nos ajudar a manter o foco no que realmente importa e facilitar nossos próximos passos.

A tarefa de negócios neste caso é identificar padrões de uso em dispositivos inteligentes para fornecer insights sobre como a Bellabeat determinará sua estratégia de marketing. Com base nessa sentença, podemos realizar as seguintes perguntas:

- Qual público mais utiliza o dispositivo?
- Quais são as tendências no uso dos dispositivos?
- Como essas tendências podem se aplicar aos clientes da Bellabeat?
- Quais estratégias de marketing podemos adotar em virtude dessas tendências?

Responder essas perguntas é fundamental para o sucesso da análise e para providenciar os insights que a equipe de Marketing está buscando.

Fase de preparação

O processo de preparação consiste em extrair os dados necessários para a análise, organizá-los, checar sua confiabilidade, armazená-los de forma segura e fornecer acesso aos demais funcionários envolvidos no projeto.

Os dados

Este conjunto de dados contém informações pessoais de trinta usuários do Fitbit. Os trinta usuários elegíveis consentiram com o envio de dados do rastreador pessoal, incluindo minutos de atividade física, frequência cardíaca, monitoramento do sono, e número de passos que podem ser usados para explorar os hábitos dos usuários.

Inicialmente, o conjunto de dados consistia em 14 arquivos CSV, e foram fornecidos pela CEO Urška Sršen. Cada arquivo possui dados relacionados a um segmento distinto, por exemplo: um arquivo contém dados sobre número de passos, já outro contém dados sobre o número de horas dormidas.

Confiabilidade dos dados

Ao realizar uma análise superficial, pode-se reparar que existem mais usuários (33) do que a quantia mencionada pela fonte dos dados (30).

Existe uma grande possibilidade de a análise sofrer viés de seleção, já que o número de pessoas consideradas para a pesquisa não é capaz de representar o público total da Bellabeat. Embora não tenha sido fornecida uma referência para o cálculo de amostragem, prosseguiremos com a análise.

Embora os dados tenham sido fornecidos pela CEO da empresa, os mesmos foram fornecidos por um terceiro (Amazon Mechanical Turkish) e podem estar desatualizados já que foram coletados 7 anos atrás (2016).

Considerando a possibilidade de viés, o fato da base de dados ser fornecida por terceiros, e a idade dos dados, é recomendável não realizar análises utilizando esta base de dados, pois ela pode levar a decisões incorretas.

Organizando os dados no Microsoft Excel

Para uma melhor organização dos dados, decidi criar uma única pasta de trabalho com cada categoria separada em diferentes planilhas, sendo que uma delas contém todos os dados em uma única tabela. Para isso, importei cada um dos arquivos CSV para a pasta de trabalho utilizando o seguinte caminho:

Painel “Dados” > Obter dados externos > De texto.

Nesta aba, selecionei a opção de tipo de campo “Delimitado”, e habilitei a opção “Meus dados possuem cabeçalhos”. Na aba seguinte, selecionei o delimitador como “Virgula”, pois as colunas estão separadas por esse caractere. Na aba final, converti o formato de decimais do formato americano para o brasileiro (vírgula para decimal, ponto para milhar), classifiquei o formato de cada coluna entre Texto, Inteiro e Data.

Preparando o RStudio

Com uma versão da linguagem R e do software RStudio já instalados no computador, o primeiro passo foi instalar os pacotes necessários para o projeto. O comando padrão para a instalação é “install.packages()”, sendo que o argumento da função será o pacote desejado. Para este projeto, instalei somente o pacote “tidyverse”, pois ele contém a maior parte das funções que serão utilizadas no processo.

Em seguida, importei os arquivos CSV “SleepDay”, “Merged” e Weight que contém os dados previamente organizados no Excel utilizando os seguintes comandos:

```
> library(readr)

> BellabeatData <- read_csv("Matheus/Estudo de caso/BellabeatData.CSV",
+   col_types = cols(Id = col_character(),
+   `Activity Date` = col_date(format = "%d/%m/%Y"),
+   `Total Steps` = col_integer(), `Fairly Active Minutes` = col_integer(),
+   `Lightly Active Minutes` = col_integer(),
+   `Sedentary Minutes` = col_integer(),
+   `Calories` = col_integer()))
```

```
Sleep <- read.csv("Matheus/Estudo de caso/sleepDay_organized.csv",
col_types = cols(Id = col_character(),
  SleepDay = col_date(format = "%m/%d/%Y"),
  TotalSleepRecords = col_integer(),
  TotalMinutesAsleep = col_integer(),
  TotalTimeInBed = col_integer()))
```

```
Weight <- read_csv("Matheus/Estudo de caso/weight.csv",
col_types = cols(
  Id = col_character(),
  Date = col_date(format= "%d/%m/%Y"),
  WeightKg = col_double(),
  WeightPounds = col_double(),
  Fat = col_integer(),
  BMI = col_double(),
  IsManualReport = col_guess(),
))
```

Com estes comandos, os arquivos CSV foram importados e todos os dados estão com o tipo correto.

Fase do processamento

Esta fase do ciclo consiste basicamente no tratamento dos dados, limpando valores em branco, possíveis erros e dados inválidos. Nela, concentrarei todo o processo de limpeza no RStudio, utilizando a linguagem R para tratar os dados.

Log de comandos e processos de limpeza

Considerando que ambas as bases de dados contém apenas números, o processo de limpeza pode ser simplificado. Aqui está um passo a passo das mudanças realizadas:

1- Realizando um backup do dataset

```
BellabeatDataBCK <- BellabeatData
```

2- Excluindo linhas com valores nulos

```
BellabeatData[na.omit(BellabeatData)] <- 0
```

3- Verificando valores fora do padrão

```
linha_com_letra <- grep("[A-Za-z]", BellabeatData$`Activity Date`)
```

4- Removendo duplicatas

```
BellabeatData <- distinct(BellabeatData)
```

5- Removendo espaços em branco

```
BellabeatData <- BellabeatData %>%  
  mutate_all(trimws)
```

Após a conclusão dessa etapa, extraí as tabelas processadas como CSV para utilizar os dados no BigQuery. O comando utilizado foi o seguinte:

```
write.csv(Sleep, "Matheus/Estudo de caso/Sleep.csv", row.names = FALSE)  
write.csv(BellabeatData, "Matheus/Estudo de caso/Merged.csv", row.names = FALSE)
```


Obs: Foi necessário retirar as aspas do arquivo CSV antes de carregá-lo no BigQuery. Para isto, utilizei a ferramenta “Localizar e substituir” do bloco de notas.

Explicação de cada etapa

Na etapa 1, eu realizei um backup da base de dados para manter a integridade original dos dados. Isso é importante porque não existe uma ferramenta para “desfazer” ações no RStudio.

Na etapa 2, eu excluí linhas que continham valores nulos, visto que o estudo não informa se há uma alternativa para substituir esses dados sem afetar a integridade dos dados.

Na etapa 3, considerando que todas as colunas contém somente números, procurei por qualquer valor diferente de um número. Nenhum valor foi encontrado.

Na etapa 4, removi todas as duplicatas.

Na etapa 5, removi todos os espaços em brancos.

Fase de análise

Nesta fase, utilizamos os dados tratados para responder as perguntas que criamos na etapa de questionamento. Isso é possível realizando uma análise exploratória dos dados para buscar tendências, anomalias e KPI's.

A ferramenta que escolhi para esta etapa do processo poderia ser qualquer uma das que tenho usado até o momento, no entanto, optei por usar o SQL integrado na plataforma BigQuery do Google.

Para auxiliar o analista, durante a fase de análise é comum o uso de gráficos para encontrar padrões ou anomalias. No meu

caso, contarei com a nova ferramenta de gráficos integrada do BigQuery. No entanto, por permitir visuais com qualidade superior, a parte gráfica deste documento será gerada via PowerBI Desktop.

Respondendo perguntas

Qual público mais utiliza o dispositivo?

Para responder essa pergunta, é essencial determinarmos a divisão do público em questão. Nossa base de dados contém dados de atividade física, horas dormidas, passos e frequência cardíaca. Isso nos possibilita dividir o nosso público em “pessoas saudáveis” e “pessoas sedentárias”.

No entanto, chegamos a mais uma indagação. Como diferenciamos pessoas saudáveis de pessoas sedentárias? Para determinarmos essas métricas utilizarei as recomendações da WHO (*World Health Organization*) que define um adulto saudável como:

- *devem realizar pelo menos 150–300 minutos de atividade física aeróbica de intensidade moderada; ou*
- *Pelo menos 75–150 minutos de atividade física aeróbica de intensidade vigorosa; ou uma combinação equivalente de atividade de intensidade moderada e vigorosa durante a semana*

World Health Organization em: www.who.int/news-room/fact-sheets/detail/physical-activity

Obs: Em nossos dados, podemos reparar usando apenas algumas ferramentas de ordenar que, alguns usuários ultrapassam a margem entre os valores citados pela WHO, por isso, em nossas análises não utilizaremos BETWEEN, e sim MAIOR QUE (>) o valor mínimo (150min moderada, 75min intensa). Vale lembrar também que estamos analisando um período de 1 mês, então se usarmos uma função de agrupamento de valores, o mínimo seria 600 moderada e 300 intenso (150*4 semanas, 75*4 semanas).

Considerando essas métricas, utilizei a seguinte consulta no BigQuery para encontrar a resposta.

```
SELECT
  COUNT(DISTINCT id)/33*100
FROM(
  SELECT
    Id,
    SUM(Fairly_Active_Minutes) AS Total_Fairly,
    SUM(Very_Active_Minutes) AS Total_Very,
  FROM
    `spartan-vertex-394720.Bellabeat.Merged`
  GROUP BY
    Id
)
WHERE
  Total_Fairly > 600
  OR Total_Very > 300
```

Esta consulta indica que 54% do público estudado possui um hábito de vida saudável. Seria uma estratégia de marketing interessante investir recursos para alcançar o público fitness, já que esse nicho específico tem demonstrado interesse pelo produto.

Qual a tendência de uso dos dispositivos?

Assim como na pergunta anterior, devemos estabelecer algumas métricas. Iremos estabelecer as métricas da seguinte forma:

- Para considerarmos que uma pessoa utiliza determinada função frequentemente, ela deve utilizá-la mais dias do que metade dos dias estudados. Assim, se uma pessoa utilizou o monitoramento de sono por 25 dias, ela será considerada uma pessoa que utiliza o monitoramento de sono, pois ela usou a função mais do que a metade do mês.
- No final, contamos quantas pessoas são válidas para serem consideradas utilizadores frequentes e dividiremos

pelo público total, chegando finalmente na percentagem de uso de cada função da FitBit.

Utilizaremos essa porcentagem para definir de acordo com a seguinte tabela:

| Entre | Será considerada |
|------------|--------------------------|
| 75% e 100% | Muito utilizada |
| 50% e 74% | Frequentemente utilizada |
| < 49% | Pouco utilizada |

Assim, se uma determinada função tiver 78% das pessoas utilizando-a, ela será considerada muito utilizada.

Durante corridas/caminhadas

Para definir quantas pessoas utilizam a FitBit para correr, utilizei o seguinte código:

```
SELECT
  COUNT(id)/33*100 AS Percentage
FROM(
  SELECT
    id,
    COUNT(Total_Distance) AS Times_used
  FROM
    `spartan-vertex-394720.Bellabeat.Merged`
  WHERE
    Total_Distance > 5
  GROUP BY
    Id
)
WHERE
  Times_used > 15
```

O código retorna o valor de 51% como resultado da média geral de todos os candidatos. O que coloca corridas e caminhadas como uma função “frequentemente utilizada”.

Durante o descanso

Para definir quantas pessoas utilizam a FitBit para dormir, utilizei o seguinte código:

```
SELECT
  COUNT(DISTINCT id)/33*100 AS Percentage
FROM(
  SELECT
    id,
    COUNT(SleepDay) AS Times_Used
  FROM
    `spartan-vertex-394720.Bellabeat.Sleep`
  GROUP BY
    Id
)
WHERE
  Times_Used > 15
```

O código retorna o valor de 39% como resultado da média geral de todos os candidatos. O que coloca monitoramento de sono como uma função “pouco utilizada”.

Registrar peso

Este caso é diferente dos demais pois não podemos usar dias como medida de frequência, visto que a maioria das pessoas não se pesa diariamente, pois a diferença muitas vezes é insignificante. Ao invés disso, as pessoas costumam se pesar por mês. Por isso, neste caso iremos adotar o seguinte formato: nós iremos calcular quantas pessoas utilizaram a função de registrar o peso no mês estudado. Para isso, utilizei a seguinte instrução:

```
SELECT
  COUNT(DISTINCT Id)/33*100 AS Percentage
FROM
  `spartan-vertex-394720.Bellabeat.Weight`
```

Este comando obteve o resultado de 24%, o que significa que apenas 8 pessoas das 33 estudadas utilizam esta função. Isso a coloca na categoria de “pouco utilizada”, e a função menos utilizada na análise.

Existe uma relação entre o público e a tendência de uso?

Ao realizar as análises previamente citadas, é possível reparar uma possível tendência. Pense comigo, temos dois públicos utilizando a pulseira, um saudável e outro sedentário. Também temos duas funções consideravelmente utilizadas, uma de monitoramento de sono e outra de corrida.

Com base nisso, podemos realizar mais uma pergunta para nossos dados. Existe uma relação entre os dois públicos e a tendências de uso?

```
SELECT COUNT(DISTINCT id)
FROM (
  SELECT DISTINCT m1.id
  FROM (
    SELECT
      Id,
      SUM(Fairly_Active_Minutes) AS Total_Fairly,
      SUM(Very_Active_Minutes) AS Total_Very
    FROM `spartan-vertex-394720.Bellabeat.Merged`
    GROUP BY Id
  ) AS m1
  WHERE
    (m1.Total_Fairly > 600 OR m1.Total_Very > 300)
  AND m1.id IN (
    SELECT DISTINCT m2.id
    FROM (
      SELECT
        id,
        COUNT(Total_Distance) AS Times_used
      FROM `spartan-vertex-394720.Bellabeat.Merged`
      WHERE Total_Distance > 5
```

```
GROUP BY Id
) AS m2
WHERE m2.Times_used > 15
)
)
```

Esta consulta mostra que das 18 pessoas saudáveis, 15 utilizam o monitoramento de corrida.

Resumo das descobertas

Com base nas análises realizadas, podemos concluir que um pouco mais que a metade (54%) dos usuários da Fitbit são pessoas fisicamente ativas. O restante do público (46%) não cumpriu os padrões recomendados pela OMS de tempo de atividade física para se enquadrarem no grupo fisicamente ativo.

De acordo com a análise, também pudemos perceber que a função mais utilizada pelo público é a de monitoramento de caminhadas e corridas (51% das pessoas utilizam), seguida pelo monitoramento de sono (39% das pessoas utilizam). Vale a pena destacar que a função menos utilizada é a de registrar peso, onde apenas 8 das 33 pessoas analisadas utilizaram a função pelo menos uma vez no período estudado.

Ao realizar estas análises, reparei que poderia haver uma relação entre o número de pessoas que utilizavam o monitoramento de corrida e as pessoas fisicamente ativas. Ao realizar uma análise em cima dessa tese, cheguei a conclusão de que das 18 pessoas saudáveis, 15 utilizam o monitoramento de corrida (83% do público).

Fase do compartilhamento

A fase de compartilhamento pode ser definida como o processo de comunicar as descobertas da análise com as partes interessadas. Para facilitar o processo de compreensão, essa comunicação geralmente conta com o auxílio de gráficos.

Existem diversos softwares com ferramentas de visualização de dados (Data Viz) no mercado, como Tableau, Power BI, Excel, etc. No nosso caso, utilizaremos o Microsoft Power BI.


Neste estudo, colocarei os gráficos individualmente neste documento seguido pela descrição de seus aspectos e de sua criação.

Carregamento de dados no Power BI

Nós temos duas opções viáveis para carregar nossos dados no Power BI. A primeira delas é conectar diretamente ao banco de dados do BigQuery usando o ID do projeto no modo Importar ou DirectQuery. Essa citada, porém, só é viável para banco de dados pequenos, já que grandes bancos de dados podem afetar a performance do Power BI e levar a um crash (falha crítica no software). Outra opção seria trazer os dados previamente filtrados por uma consulta, o que diminuiria o custo de performance e reduziria a necessidade de criar diversas medidas e fórmulas no Power BI.

Para este caso, optei por trazer os dados previamente filtrados por uma consulta.

O público da FitBit



O gráfico acima parte da divisão do público da FitBit em dois: pessoas fisicamente ativas e pessoas sedentárias. A equipe de Analytics utilizou os critérios da World Health Organization para determinar a categoria de cada indivíduo do estudo. O resultado mostrado acima é a contagem de quantos indivíduos que utilizam o dispositivo são ativos ou sedentários.

Como podemos notar, um pouco mais da metade dos usuários da FitBit são fisicamente ativos. Portanto, voltar nossa estratégia de marketing para o público Fitness pode trazer um aumento no

número de usuários do dispositivo, já que este nicho específico parece demonstrar interesse pelo produto.

Processo de criação

Após importar os dados por uma consulta SQL e tratá-los apropriadamente no Power Query, foi necessário criar uma coluna que contém as categorias de cada ID. Para realizar tal feito, eu utilizei a ferramenta de Coluna condicional, onde os critérios lógicos são:

SE Total_Fairly > 600 RETORNE Ativo

SE Total_Veery > 300 RETORNE Ativo

SENÃO Sedentário

Com este processo, os dados agora possuem uma coluna qualitativa que permite legendar o gráfico.

Justificando os aspectos do gráfico

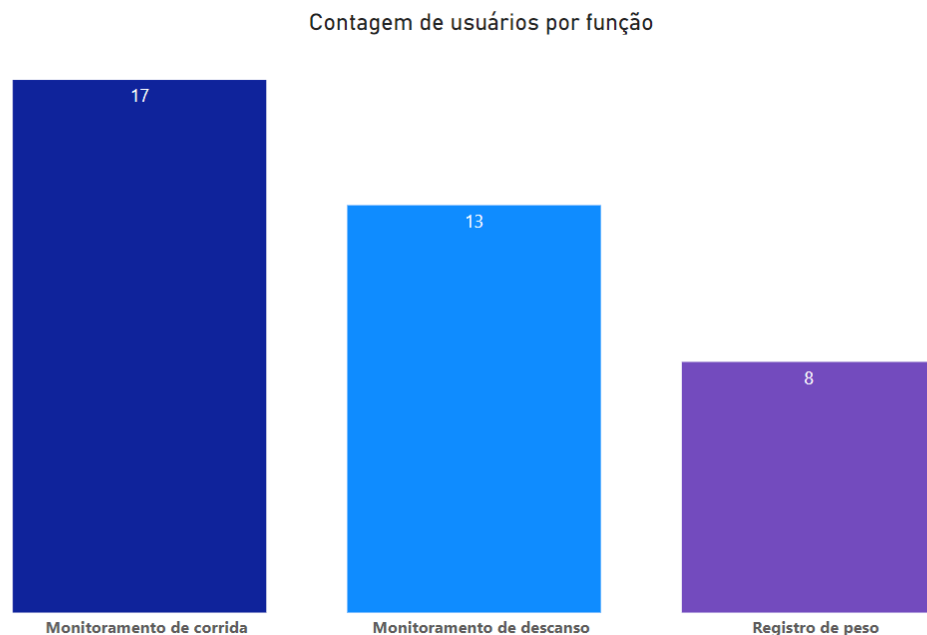
Como estamos categorizando os dados, um gráfico de pizza me pareceu uma boa opção para comunicar a mensagem que estamos tentando passar. Com o auxílio de rótulos, é possível tornar o gráfico de pizza ainda mais informativo, já que sem eles o gráfico pode transmitir apenas o sentido de maior grandeza, sem entrar em detalhes quantitativos explícitos.

Neste caso eu também poderia utilizar um gráfico de colunas, rosca ou até mesmo barras. Todas essas opções transmitiriam a mensagem que estou tentando passar.

Optei por incluir duas informações de rótulo: a quantidade e a porcentagem. Neste, e na maioria dos casos, apenas a

porcentagem como rótulo já seria o suficiente. Porém, por estarmos trabalhando com um número relativamente pequeno de pessoas, eu decidi manter o número exato da contagem para auxiliar na cognição das grandezas.

As funções mais utilizadas da FitBit



Como podemos ver no gráfico, a função mais utilizada pelos usuários da Fitbit é a de monitoramento de corrida, com 51% do público utilizando esta função. Em seguida, temos o monitoramento de descanso, com 39% do público total utilizando-a. E por fim, a função menos utilizada é a de registrar peso, onde apenas 24% do público estudado utilizou a função pelo menos 1 vez no mês.

Considerando que metade do público utiliza a função de monitoramento de corrida, e também que mais da metade do público está ligada ao meio fitness, focar a estratégia de marketing no meio esportivo seria uma boa opção para aumentar o interesse pelo dispositivo.

Processo de criação

Após importar os dados por uma consulta SQL, que continha os id's e a quantidade de dias utilizando determinada função foi necessário realizar os seguintes passos para cada CSV no Power Query:

1. Criar colunas condicionais em que valores maiores que 15 tivessem o nome de suas respectivas funções em cada CSV.
2. Aplicar procedimentos padrões de tratamento (remover vazios, alterar tipo, remover colunas, etc.).
3. Acrescentar consultas como novas (já que todas têm o mesmo nome de coluna "id" e "Função").

Com este processo, os dados agora possuem uma coluna contendo o número de vezes que cada função foi utilizada. Em seguida, bastou apenas colocar "Função" no eixo X, e "Contagem de Função" no Eixo Y do gráfico.

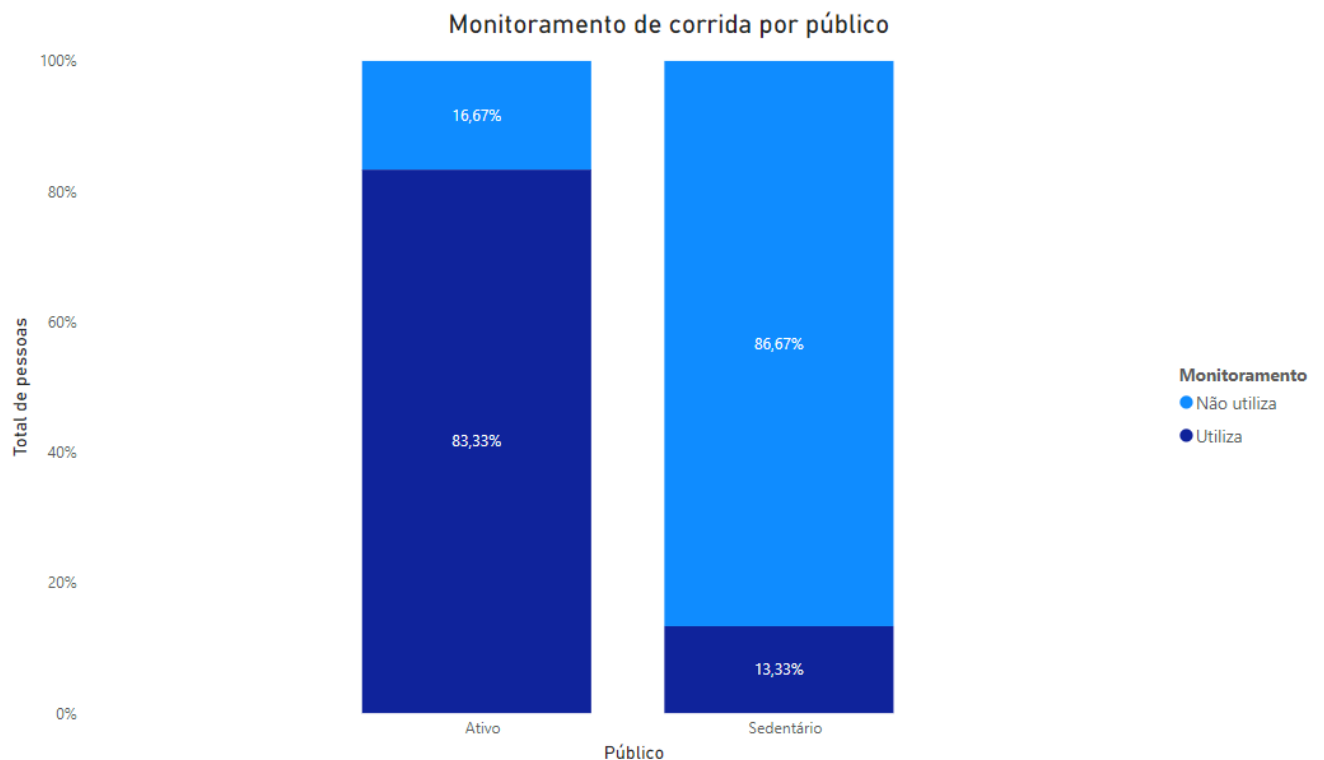
Justificando os aspectos do gráfico

Optei por utilizar um gráfico de colunas nesta opção porque ele é ideal para comparar quantidades entre categorias e transmitir a mensagem que estamos tentando passar.

Durante o processo de criação, eu removi características desnecessárias como títulos de eixo (já que o apenas o título possibilita a compreensão), e valores de eixo. Em seguida, adicionei um rótulo de dados para tornar os números de cada categoria visível.

Para esta mensagem, também teríamos um resultado semelhante se utilizássemos um gráfico de barras horizontais, ou até mesmo um gráfico de rosca ou pizza.

Relação entre público e função



Neste gráfico podemos analisar a quantidade de pessoas em cada público que utilizam o monitoramento de corrida. Podemos notar que 83% do público ativo utiliza o monitoramento de corrida, o que pode justificar o fato do monitoramento de corrida ser a função mais utilizada, já que o público ativo também representa maioria no uso da FitBit.

A equipe de analytics também realizou o mesmo processo de análise para as demais funções. Porém o seu resultado não parece demonstrar nenhuma relação significativa.

Processo de criação

Utilizando as tabelas criadas ao importar os arquivos CSV nas apresentações anteriores, tudo o que tive que fazer foi mesclar a tabela que continha os dados do público ativo com a tabela que continha os dados do monitoramento de corrida. Para mesclar as duas tabelas, utilizei a coluna “id” como chave e um LEFT OUTER JOIN. Em seguida, apenas substitui os valores “Monitoramento de corrida” por “utiliza”, e os valores “null” por “não utiliza”. Após isso, realizei os procedimentos padrões de tratamento de dados.

Justificativa dos aspectos do gráfico

Inicialmente, quando pensamos em representar possíveis relações entre fatores distintos, o gráfico de dispersão já vem em nossa mente. Porém não seria possível utilizá-lo neste caso porque ele requer uma variedade numérica, e este não é o nosso caso. O objetivo era representar a quantidade de pessoas em uma categoria que também está em outra, ou seja, um gráfico que possa categorizar os dados. Por isso, a minha escolha foi um gráfico de coluna 100% empilhada.

Eu também poderia utilizar gráficos de rosca ou pizza, mas estes não seriam eficientes quanto um gráfico de barras ou colunas 100% empilhadas, já que estes citados transmitem uma sensação de segmentação mais eficiente para este caso.

Fase da ação

Após responder todas as perguntas feitas na fase de preparação através de uma análise e do compartilhamento de seus resultados através de visualizações, chegou a hora de orientarmos a equipe ao resultado.

As recomendações da equipe de analytics é a seguinte:

É recomendável focar as estratégias de marketing no público saudável/fitness, pois estes são a maioria no uso do dispositivo.

Podemos atrair esse público utilizando a função “Monitoramento de corrida” como atrativo. Já que quase todas as pessoas ativas têm demonstrado interesse nesta função.